MACHINE LEARNING CANVAS · MiBici

Diseñado para: MiBici (AMG) Diseñado por: Equipo 26

TAREAS DE ML

Qué estimamos, para qué unidad y con qué horizonte.

P1 · Demanda del día siguiente. Predeciremos el total de viajes que comenzarán en cada estación durante el día siguiente. Por ejemplo, al cerrar el lunes estimaremos los viajes del martes. Es regresión porque el resultado es una cantidad.

P2 · Riesgo estimado del día siguiente. Asignaremos una categoría por estación y día: riesgo estimado de quedarse sin bicicletas, riesgo estimado de quedarse sin espacios disponibles o sin riesgo elevado estimado. Conservaremos el primer umbral que alcance el indicador durante ese día. Si después aparece el otro tipo de riesgo, la etiqueta diaria no lo reflejará.

P3 · Patrones de uso. Agruparemos estaciones con horarios de salidas y llegadas semejantes y ubicaremos los grupos en un mapa. Es un análisis descriptivo; no predice un evento del día siguiente.

Alcance. P1 mide viajes observados; P2 estima el riesgo a partir de los viajes y la capacidad; no confirma el inventario real.

DECISIONES

Cómo podrían utilizarse los resultados.

P1. El operador podría anticipar las estaciones con más viajes y preparar la distribución de bicicletas y personal. Para decidir cuántas bicicletas colocar también necesitaría conocer la disponibilidad real.

P2. El equipo de rebalanceo podría preparar una lista de estaciones para revisar primero. “Top-K” significa seleccionar las K de mayor prioridad, según las probabilidades del modelo y la capacidad de atención del equipo.

Antes de trasladar bicicletas, se comprobaría si conviene surtir o liberar espacios en cada estación. Una alerta del indicador no basta para ordenar un traslado.

P3. Planeación urbana podría comparar grupos y estudiar sus zonas. Los resultados orientarían preguntas sobre expansión, junto con otros datos territoriales.

Por acordar. Tamaño de la lista y nivel de alerta que justificaría una revisión.

PROPUESTA DE VALOR

A quién ayudaría y qué problema atendería.

Proponemos apoyar la planeación de MiBici con información sobre la demanda esperada para el día siguiente, las estaciones que podrían requerir atención y los patrones de uso en la ciudad.

Usuarios previstos. El operador del sistema usaría P1; el equipo de rebalanceo, P2; y planeación urbana, P3. El beneficio esperado para las personas usuarias sería encontrar bicicletas y espacios disponibles con mayor frecuencia.

Problema. Los registros de viajes muestran movimientos, pero no el inventario de cada estación ni los traslados del operador. Por eso el riesgo de P2 debe aproximarse y sus límites deben quedar claros.

Objetivo de esta entrega. Construir una base reproducible y evaluar modelos sencillos. La mejora de la operación es una hipótesis que todavía necesitaría comprobarse.

RECOLECCIÓN DE DATOS

Cómo obtendríamos y actualizaríamos el conjunto.

Periodo propuesto. Agosto de 2025 a septiembre de 2026. El año de entrenamiento incluye distintas temporadas, como vacaciones y las diferencias de uso entre verano y otoño, además de varias repeticiones de cada día de la semana. Confirmaremos el alcance después de revisar su cobertura.

Proceso. Un comando en dataset.py descargaría los archivos, normalizaría columnas, codificación y fechas, y guardaría datos preparados en Parquet. La limpieza documentaría duplicados y registros inválidos.

Trazabilidad. El manifiesto guardaría URL, fecha de descarga, SHA-256 y conteos originales. Los conteos limpios se registrarían aparte. La versión de datos acompañaría cada experimento.

Reproducción. El repositorio incluiría código e instrucciones. Los datos, modelos y carpetas de MLflow quedarían fuera de Git. Incorporaríamos nuevos meses con el mismo proceso.

FUENTES DE DATOS

De dónde provienen los registros y sus límites.

MiBici. Usaremos los CSV mensuales de viajes: inicio, fin, origen y destino. Septiembre contiene 490,056 registros originales; el total limpio y el del periodo deben obtenerse desde código.

Estaciones. El catálogo de septiembre tiene 484 registros con identificador, ubicación y capacidad. Aplicar esa capacidad a meses previos es un supuesto que debemos revisar. Capacidad nula o desconocida impide calcular P2.

CityBikes. Se propone contrastar el indicador de P2 con su disponibilidad histórica. Primero revisaremos fechas, estaciones, zonas horarias y periodos sin observaciones. La comparación sigue pendiente.

Privacidad y uso. No usaremos identificadores de usuarios, género ni nacimiento como variables. Documentaremos por separado las condiciones de cada fuente y evitaremos datos personales en MLflow.

EVALUACIÓN DEL IMPACTO

Cómo compararíamos los modelos y sus errores.

Partición. Proponemos entrenar con agosto de 2025 a julio de 2026, elegir configuraciones con agosto de 2026 y reservar septiembre de 2026 para la evaluación final. Las variables solo usarán información conocida antes de cada pronóstico.

P1. MAE indica el error promedio en viajes. RMSE da más peso a errores grandes. WAPE complementa la lectura con el error relativo al volumen total, cuando este es positivo.

P2. F1 macro da el mismo peso a cada categoría. La sensibilidad indica qué proporción de casos detectamos. Recall@K mide cuántas estaciones con riesgo estimado según el indicador aparecen en la lista priorizada.

P3. Silhouette ayuda a evaluar la separación de los grupos. También revisaremos que sus perfiles horarios y su distribución en el mapa sean interpretables.

Consecuencias. Una omisión podría dejar una estación fuera de la revisión; una alerta falsa podría generar trabajo innecesario. No estimaremos ahorros sin información del operador.

Criterios de avance. Superar la referencia sería una razón para continuar el prototipo. El despliegue requeriría además datos recientes, tiempos adecuados y validación operativa.

Revisión por zonas. Compararemos errores por estación y municipio, cuando dispongamos de esa ubicación. Esto ayuda a detectar diferencias; no garantiza equidad por sí solo.

GENERACIÓN DE RESULTADOS

Cuándo se ejecutarían las predicciones.

Cada noche, proponemos generar P1 y P2 para el día siguiente. En el prototipo simularemos ese proceso sobre el histórico, avanzando día por día y usando solo la información disponible hasta el corte.

Ejemplo. Para pronosticar el martes usaríamos los viajes anteriores y su calendario, nunca los viajes del propio martes como entradas.

Horario pendiente. P1 puede contar de medianoche a medianoche. Como P2 reinicia a las 05:00, debemos acordar si su día operativo abarca hasta las 05:00 siguientes y fijar el corte de información.

Límite operativo. Los CSV se publican mensualmente. Para ejecutar el sistema en la operación diaria necesitaríamos una fuente actualizada antes de cada pronóstico.

Recursos. Empezaremos en una computadora local y mediremos tiempos. P3 se revisaría al incorporar nuevos periodos, sin necesidad de recalcular grupos cada noche.

Cómo se consultaría. Una tabla mostraría por estación los viajes previstos, la categoría de riesgo estimado y su prioridad de revisión. Un mapa permitiría explorar los grupos de uso y su ubicación.

Ejemplo de lectura. Una estación con muchos viajes previstos y riesgo estimado de quedarse sin bicicletas podría revisarse antes de empezar la jornada. Eso no determina automáticamente cuántas bicicletas necesita.

Qué entregaríamos ahora. El canvas, la propuesta técnica, el repositorio reproducible y los experimentos base registrados en MLflow. La interfaz operativa y el despliegue serían pasos posteriores.

Para discutir con el equipo. Confirmar el periodo, el día operativo de P2, los supuestos de ocupación inicial, las métricas y el reparto de trabajo. Los resultados numéricos deberán salir del notebook del repositorio.

CONSTRUCCIÓN DE MODELOS

Con qué referencias y candidatos empezaríamos.

P1. La referencia será el promedio de viajes del mismo día de la semana durante las cuatro semanas previas. Para un martes, usaríamos los cuatro martes anteriores disponibles. El candidato será HistGradientBoostingRegressor con pérdida Poisson, orientado a conteos.

P2. La referencia repetirá la categoría del mismo día de la semana anterior. Compararemos con regresión logística multiclase, que estima probabilidades para las tres categorías. Boosting sería una mejora posterior.

P3. Empezaremos con KMeans y compararemos con agrupación jerárquica. Elegiremos el número de grupos considerando separación e interpretación, antes de la evaluación final.

Registro. Cada pregunta tendrá al menos una ejecución base desde código. MLflow guardará parámetros, fechas, versión de datos, semilla, métricas, artefactos y commit.

Actualización. Se propone revisar los modelos con cada nuevo mes y definir cómo atender estaciones con poca historia.

VARIABLES DE ENTRADA

Qué información ayudaría a cada modelo.

Para P1 y P2, usaremos salidas y llegadas del último día conocido, el mismo día de la semana previa y promedios de 7 y 28 días. También podremos incluir calendario del día futuro, capacidad y ubicación.

Datos adicionales. Festivos, vacaciones y municipio requerirán fuentes y reglas documentadas. Para P2 podremos usar extremos del indicador y frecuencia de categorías de días ya observados.

Ceros y ausencias. Un periodo tendrá cero viajes si hay cobertura y no se registran movimientos. Si desconocemos la cobertura, lo marcaremos como ausente. No descartaremos días porque después observemos una inactividad prolongada.

Para P3, construiremos perfiles de salidas y llegadas por hora y día de la semana. Los normalizaremos para comparar la forma del uso, conservando el volumen por separado.

Sin información futura. La etiqueta del día a pronosticar nunca será una variable de entrada. Las transformaciones se ajustarán con entrenamiento.

Etiqueta de P2. Acumularemos salidas menos llegadas desde las 05:00 y dividiremos entre capacidad. Con ocupación inicial supuesta del 50 %, ≥ 0.5 indica riesgo estimado de quedarse sin bicicletas y ≤ −0.5 indica riesgo estimado de quedarse sin espacios disponibles.

Ejemplo. Con capacidad 20, diez salidas netas alcanzan 0.5. No reconstruye inventario ni rebalanceo. Proponemos probar ocupación inicial de 40–60 %, ajustando también los umbrales.

MONITOREO

Qué revisaríamos al incorporar nuevos datos.

Cada mes, revisaríamos cobertura, faltantes, nuevas estaciones, cambios de capacidad y cambios en los patrones de viajes. Compararíamos el desempeño reciente con el de los modelos de referencia.

Seguimiento técnico. Registraríamos errores de P1, detección de categorías y calidad de la lista de P2. En P3 revisaríamos si los grupos siguen siendo interpretables.

Trazabilidad. Cada evaluación y actualización tendría su versión de datos y código. Las métricas identificarían el conjunto o periodo evaluado.

Impacto operativo futuro. Medir tiempos con estaciones vacías o llenas y traslados útiles requeriría disponibilidad observada y registros del operador.

Comprobación pendiente. Se propone contrastar P2 con CityBikes. El desempeño sobre nuestras etiquetas no demuestra por sí solo una reducción de incidentes reales.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing. · Adaptación ampliada al español para el proyecto MiBici.

OWNML.CO